BAB I
PENDAHULUAN

1.1 Latar Belakang

Konektivitas antara manusia di era modern merupakan sesuatu yang tersedia secara luas dengan adanya perkembangan teknologi berupa internet dan media sosial. Kemp (2020) memperkirakan bahwa dari seluruh populasi manusia sebanyak 7,81 miliar, 4,66 miliar memiliki akses internet dan 4,14 miliar lainya merupakan pengguna media sosial yang aktif. Khususnya di indonesia, APJII (2020) mencatat bahwa sebanyak 196,71 juta jiwa penduduk di indonesia memiliki akses internet, dengan penetrasi total sebesar 73,7%. Ketersambungan manusia dalam skala sedemikian besar yang difasilitasi kedua teknologi tersebut, khususnya media sosial, dapat menjadi peluang untuk memajukan aktivitas bisnis dan komersial.

Persebaran paparan suatu merek dagang di media sosial berkorelasi dengan jumlah penjualan merek dagang tersebut, dan media sosial juga mempermudah interaksi antara konsumen dan perusahaan (Alves , Fernandes, & Raposo, 2016; Marshall, Moncrief, Rudd, & Lee, 2012 ; Yao et ak.,2019). Media sosial juga memberikan kesempatan bagi konsumen yang memiliki pengalaman positif dengan suatu merek dagang untuk menyebarkan promosi merek tersebut berupa *e-word of mouth* (e-WOM) secara organik (Punel & Ermagun, 2018). Penelitian terdahulu (Peralta, 2019; Wielki, 2020) mencatat bahwa sedang terjadi peralihan tren di bidang pemasaran, yang beralih dari pendekatan tradisional menuju pendekatan pribadi di ruang media sosial. Oleh karena itu, penting bagi suatu perusahaan komersial untuk bisa menetapkan eksistensi media sosial yang signifikan. Keberadaan media sosial suatu yang demikian tidak hanya berkaitan dengan pemasaran, tetapi juga penanganan umpan balik dari konsumen terkait produk yang dipasarkan oleh perusahaan.

Salah satu *platform* media sosial yang paling banyak digunakan khususnya di indonesia adalah Twitter. Kemp (2020) menemukan bahwa dari seluruh

pengguna internet di indonesia, jumlah pengguna yang juga aktif di media sosial mencapai 170 juta jiwa, dan sebanyak 63,6% diantaranya aktif menggunakan Twitter. Sebagai situs media sosial berbasis *microblogging*, Twitter banyak dimanfaatkan oleh pelaku sektor bisnis untuk sarana komunikasi dan layanan pelanggan (Hailong, Wenyan, & Bo, 2014) dan dapat digunakan untuk menyebarkan eksistensi *brand* produk serta menggali respon konsumen secara langsung (Damayanti,2017).

Literatur ilmiah terdahulu telah banyak meneliti pendekatan penambangan data di Twitter untuk berbagai topik, seperti politik (Budiharto & Meiliana, 2018; Hernandez-Suarez et al.,2017), Kesehatan (Rahayuningtyas, 2020; Sinnenberg et at.,2017) dan pendidikan (Domett, 2019; Pill, Harvey, & Hyndman, 2017). Ditinjau dari teknik yang digunakan, beberapa penelitian tersebut (Budiharto & Meiliana, 2018; Rahayuningtyas, 2020) melakukan *sentiment analysis* sebagai bagian dari penelitian mereka. *Sentiment analysis*, sebagaimana didefinisikan oleh Soleymani et al. (2017) adalah tugas (*task*) dalam penambangan data yang bertujuan untuk mengelompokan data dalam bentuk kalimat berbahasa tertentu ke dalam kelas positif, negatif, atau netral. Beberapa teknik yang dapat digunakan untuk melakukan *sentiment analysis* meliputi *random forest* (RF) dan *support vector machine*; kedua teknik ini telah dibandingkan dalam penelitian terdahulu ketika diterapkan pada konteks deteksi nada suatu kalimat tertulis (Pranckevicius & Marcinkevicius, 2017). Beberapa penelitian terdahulu lainya (Curiskis, Drake, Osborn, & Kennedy, 2020; Llewellyn, Favero, & Hill, 2018; Prabhakar Kaila, & Prasad, 2020) membahas penambangan data di Twitter dari segi yang berbeda, yaitu pelaksanaan *topic modelling*, yang didefinisikan oleh Prabhakar Kaila dan Prasad (2020) sebagai tugas (*task*) dalam penambangan data untuk mengelompokan data leksikal ke dalam golongan-golongan tertentu yang disesuaikan dengan suatu kategori besar atau topik.

1.2 Rumusan Masalah

Latar belakang diatas menghasilkan rumusan sebagai berikut

1) Fitur apa saja yang paling berpengaruh terhadap performa klasifikasi machine learning untuk mendeteksi karakteristik data twitter
2) Berapa nilai performa (akurasi, presisi, recall dan fl score) yang dihasilkan oleh model klasifikasi machine learning

1.3 Batasan Masalah

Batasan masalah dari penelitian ini adalah.

1. Data tweet aduan yang digunakan dalam penelitian ini akan dikumpulkan melalui API Twitter dengan menggunakan kata kunci terkait PT Garuda Indonesia. Hanya tweet aduan yang diakses secara publik yang akan digunakan dalam analisis.
2. Penelitian ini akan menggunakan sentimen analisis dengan dua metode klasifikasi, yaitu Random Forest dan Support Vector Machine,
3. Penelitian ini akan membatasi pengumpulan data dan analisis pada tweet aduan terhadap PT Garuda Indonesia yang di posting dalam periode satu tahun terakhir.

1.4 Tujuan Penelitian

Tujuan dari penelitian ini adalah.

1. Membandingkan metode klasifikasi Random Forest dan Support Vector Machine dalam analisis sentimen untuk menemukan metode dengan tingkat akurasi terbaik dalam mendeteksi tweet aduan terhadap PT Garuda Indonesia.

2. Mengidentifikasi topik yang paling penting dalam data media sosial PT Garuda Indonesia, seperti permasalahan pelayanan, kepuasan pelanggan, atau promosi produk.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Ditinjau dari sisi keilmuan, hasil penelitian ini diharapkan dapat menjadi referensi untuk penelitian di masa depan yang berfokus pada penerapan teknik penambangan data dalam konteks analitik media sosial.

1.6 Sistematik Penulisan

1. Bab 1 menjelaskan latar belakang penelitian, perumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, dan manfaat penelitian.
2. Bab 2 berisi studi literatur yang dilakukan untuk menunjukan dasar akademis penelitian, baik berupa teori-teori dasar yang menjadi landasan maupun kajian pustaka dari penelitian-penelitian relevan yang sebelumnya, dan menjelaskan hipotesis/pertanyaan penelitian.
3. Bab 3 menjelaskan objek penelitian, alur penelitian serta alat dan bahan.

BAB II
TINJAUAN PUSTAKA

2.1 Studi Literatur

2.1.1 Media sosial dan Twitter

Ada beberapa usulan dari para ahli tentang definisi ilmiah untuk media sosial. McCary-peet dan Quan-Haase(2017) mendefinisikan media sosial sebagai layanan berbasis web yang memperbolehkan banyak individu, komunitas, dan organisasi untuk berkolaborasi, berinteraksi, dan membangun komunikasi bersama dengan cara memberikan kemampuan untuk menciptakan, mengubah, membagikan, dan berinteraksi dengan konten buatan pengguna yang dapat diakses dengan mudah. Definisi ini berasal dari hasil analisis literatur serupa yang awalnya mendefinisikan media sosial secara beragam dan tidak baku (Ellison & Boyd,2013; McCary-peet dan Quan-Haase,2017).

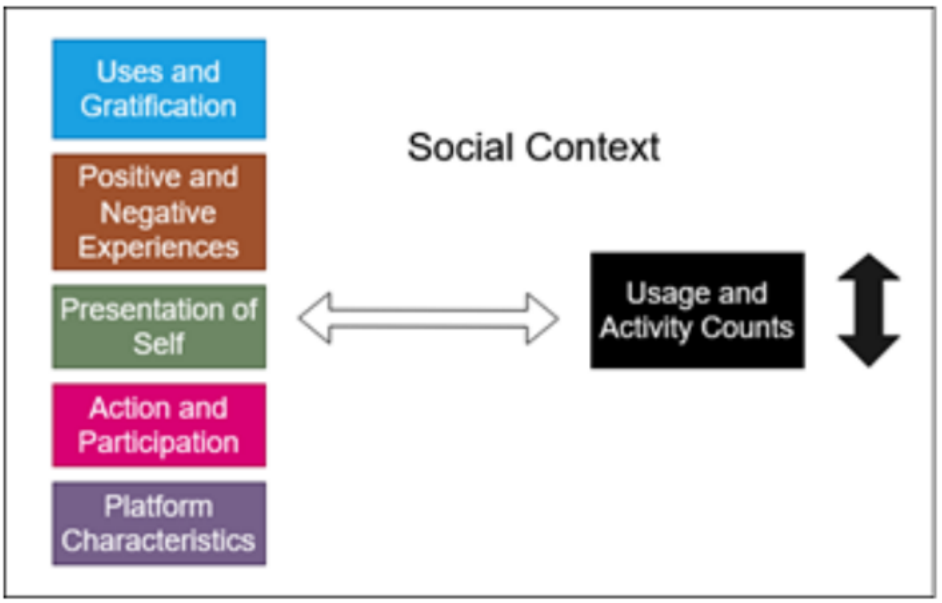

Gambar 2.1. Diagram aspek dasar penggunaan media sosial

Sumber: : (McCary-peet dan Quan-Haase,2017) diolah Kembali oleh penulis.

Masih menurut (McCary-peet dan Quan-Haase,2017), penggunaan media sosial dapat dimodelkan berdasarkan tujuan aspek dasar yaitu:

1. *Presentation of self, reputation management, and privacy* (penampilan diri sendir, manajemen reputasi pribadi, dan privasi). Aspek ini mencerminkan bagaimana seorang pengguna media sosial mengembangkan dan merubah konten profil pribadi mereka selama jangka waktu tertentu seiring dengan penggunaan media sosial tersebut secara kontinu.
2. *Action and participation* (Aksi dan partisipasi). Aspek ini berkenaan dengan iterasi yang dilakukan pengguna media sosial, baik terhadap platform media sosial tersebut ataupun dengan sesama pengguna media sosial.
3. *Uses and gratifications* (Gratifikasi dalam penggunaan). Aspek ini berkenaan dengan alasan atau motif yang mendorong partisipasi seseorang dalam suatu media sosial, misalnya peluang bersosialisasi atau bertukar informasi dengan pengguna lain
4. *Positive and negative experience* (Pengalaman positif dan negative). Aspek ini terdiri dari pengalaman dan kejadian yang dialami seorang pengguna. Pengalaman positif, seperti mendapatkan kenalan baru, cenderung mendorong pengguna untuk berpartisipasi lebih aktif; Sebaliknya pengalaman negative seperti menjadi korban penipuan atau *cyberbullying* cenderung membuat pengguna enggan berpartisipasi lebih lanjut
5. Platform characteristic (Karakteristik platform). Setiap platform media sosial memiliki fitur atau rancang bangun eksklusif yang membedakannya dari platform pesaing. Misalnya, pada *platform* Twitter, pengguna mengirimkan pesan dalam bentuk “microblog” yang tidak melebihi 280 karakter per pesan.
6. *Uses and activity counts* (Jumlah pengguna dan aktivitas). Aspek ini mencakup data kuantitatif yang berkaitan dengan penggunaan dan keterhubungan pengguna media sosial. Berbeda dengan aspek lainnya, aspek ini tidak selalu tampak atau dapat dirasakan oleh pengguna media sosial, misalnya data mengenai waktu rerata seorang pengguna mengakses situs tertentu yang disimpan oleh pihak perusahaan penyedia platform media sosial.

7. *Social context* (Konteks sosial). Menurut penjabaran McCary-peet dan Quan-Haase, aspek ini mencakup karakteristik atau kejadian yang secara khusus mempengaruhi seorang pengguna. Aspek ini diantaranya meliputi fenomena sosial di sekitar pengguna, pandangan politik pengguna, keadaan ekonomi, dan kondisi mental pengguna.

2.1.2 *Data Preprocessing*

Data preprocessing adalah proses pengubahan bentuk kumpulan data yang belum terstruktur menjadi data yang terstruktur sesuai dengan kebutuhan, yang dilakukan untuk proses penambangan yang lebih lanjut. Tahap-tahap data *preprocessing* pada korpus data teks secara umum adalah *tokenizing*, penghapusan *stopwords*, dan *stemming* (Garacia, Luengo, & Herrera, 2015).

a. Tokenization

Tokenization adalah proses memisahkan kata di dalam kalimat, paragraf atau halaman menjadi *token* atau potongan kata tunggal yang berdiri sendiri. Dalam proses ini, pemecahan kalimat dan kata dilakukan berdasarkan Batasan spasi di dalam kalimat tersebut, setelah karakter dan symbol selain alfabet (a-z) dihilangkan.

b. Penghapusan *stopwords*

stopwords adalah kata-kata yang sering muncul dalam sebuah dokumen, tapi berisi sedikit informasi yang biasanya tidak diperlukan dalam pengolahan data. Misalnya, dalam Bahasa Indonesia, kata-kata yang termasuk *stopwords* meliputi “setelah”, “lagi”, “lalu”, “sebelum”.

c. Stemming

Stemming adalah proses pencarian bentuk dasar suatu kalimat dengan cara menghilangkan imbuhanya. Stemming merupakan perwujudan normalisasi untuk korpus data berupa teks dengan cara menyederhanakan kata-kata yang terdapat dalam suatu dokumen menjadi kata dasar dengan menggunakan

aturan-aturan tertentu. Stemming untuk dokumen berbahasa Indonesia memiliki beberapa tantangan tersendiri, misalnya kata-kata “gaul” dengan perubahan ejaan atau fonem serta penambahan infiks dan imbuhan di awal dan akhir kalimat (Salsabila, Winatmoko, Septiandri, & Jamal,2018)

2.1.3 *Sentiment Analysis*

Analisis sentimen dapat dikelompokkan menjadi tiga level berdasarkan (Aprianto, 2016; Hegde & Padma, 2017), yaitu:

a. Entitas: Pada level ini, analisis sentimen fokus pada setiap kata dalam sebuah kalimat, menjadikannya sebagai cakupan paling spesifik
b. Kalimat: Pada tingkatan ini, analisis dilakukan pada seluruh kalimat, dengan sentimen ditentukan berdasarkan isi kalimat tersebut.
c. Dokumen: Level ini memiliki ruang lingkup paling luas, di mana sentimen dianalisis berdasarkan konten keseluruhan dokumen.

Satu penerapan adalah dalam klasifikasi dokumen, yang merupakan proses pengelompokan potongan teks, paragraf, atau dokumen berdasarkan metode tertentu yang menggunakan model pelatihan. Dalam analisis sentimen, klasifikasi bertujuan untuk mengkategorikan data ke dalam sentimen yang spesifik. Ada beberapa langkah dalam proses klasifikasi analisis sentimen, seperti yang diilustrasikan pada Gambar 2.2.

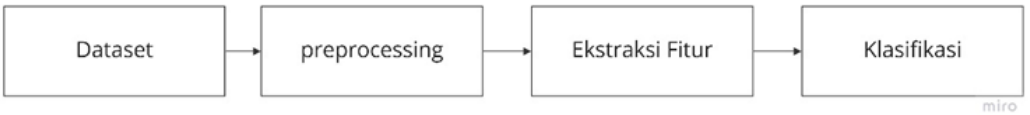

Gambar 2.2.Tahapan Klasifikasi Teks
Sumber: (Khairunnisa, 2018): diolah oleh penulis.

Tahap awal adalah preprocessing, yang bertujuan mengubah data mentah menjadi siap diolah. Pada data berbasis teks, langkah-langkah preprocessing mencakup pembersihan dataset, konversi ke bentuk kata standar, dan tokenisasi.

Terdapat berbagai cara untuk membersihkan data, seperti mengeliminasi username, hashtag, angka, dan karakter unik, atau menghapus entri berulang, tergantung pada kebutuhan spesifik.

Teks tidak bisa diolah secara langsung oleh metode klasifikasi. Maka dari itu, data yang sudah ditokenisasi di tahap preprocessing perlu diubah menjadi bentuk vektor. Bentuk vektor ini, yang digunakan dalam machine learning, sering disebut sebagai "bag of words" (BOM) atau Vector Space Model (VSM). Untuk mengonversi data menjadi bentuk vektor, data berformat token diberi indeks melalui teknik pembobotan fitur.

Setelah data dikonversi ke bentuk vektor, langkah berikutnya adalah klasifikasi. Proses klasifikasi meliputi dua langkah: pelatihan dan pengujian. Pelatihan melibatkan evaluasi performa dari data latih, dan hasil dari evaluasi ini digunakan dalam pengujian data uji.

Tabel 2.1 Keaslian Penelitian

No	nama	Tahun	Tujuan Penelitian	Metodologi dan Hasil Penelitian	Kelemahan Penelitian	Saran
1	Aprianto	2016	Penelitian ini bertujuan untuk menghasilkan ringkasan opini dan sentimen terhadap ulasan produk	Menggunakan Algoritma *Random Forest,* Dengan cara mengumpulkan data ulasan produk. Hasil penelitian menunjukan model yang efektif dalam analisis sentimen dan peringkasan pada opini pada ulasan produk.	Nilai akurasi fl-score hanya sebesar 20-40%, ukuran dataset terbatas dan ketergantungan algoritma Random Forest.	
2	Hegde	2017	Penelitian ini bertujuan untuk meningkatkan akurasi sentimen analisis dari penelitian sebelumnya dengan algoritma yang berbeda	Menggunakan 1 metode *random forest,* Hasil penelitian Menunjukan bahwa random forest menghasilkan pengklasifikasi yang baik untuk mengklasifikasikan sentimen multi class kannada dengan akurasi 72%	Meskipun mendapat akurasi yang cukup tinggi yaitu 70%, metode ini hanya diujikan pada *datase*t berbahasa Kannada	
3	A.Sharma	2017	Penelitian ini bertujuan untuk mengembangkan metode pemodelan topik analisis sentimen pada data media sosial	Menggunakan Algoritma *Latent Dirichlet* Allocation dan pemodelan topik untuk menganalisis sentimen dalam data media sosial Hasil penelitian menunjukan pendekatan topik menggunakan LDA dapat mengidentifikasi topik-topik utama dalam data media sosial	Validitas sentimen yang sulit ditemukan secara akurat dan keterbatasan dalam representasi topik yang dihasilkan	Memperluas sumber data dengan eksplorasi metode pemodelan lainya
4	C. Bi	2015	Penelitian ini bertujuan untuk mengembangkan metode pemodelan dinamis yang dapat mendeteksi peristiwa dalam aliran data media sosial secara real-time	Menggunakan metode pemodelan topik dinamis (Latent Dirichlet Allocation) Hasil penelitian menunjukan pemodelan topik dinamis dapat efektif mendeteksi perubahan topik dalam aliran media sosial	Keterbatasan representasi data dan ketergantungan pada algoritma pemodelan topik	Melibatkan sumber data yang lebih beragam dengan dengan eksplorasi metode pemodelan topik alternatif
5	M. De	2018	Bertujuan mengembangkan pendekatan interdisipliner untuk menganalisis data media sosial dengan tujuan memahami perilaku pengguna.	Metodologi penelitian ini melibatkan pengumpulan data, pembersihan data, analisis topik dan analisis sentimen Hasil penelitian menunjukan bahwa dengan menggunakan pendekatan interdisipliner, analisis media sosial dapat memberikan wawasan yang berharga bagi masyarakat.	Terbatasnya skala penelitian dan ketergantungan pada algoritma dan metode analisis	Perluasan cakupan data, gabungkan metode analisis yang berbeda

6						
7						
8						
9						
10						

2.2 Dasar Teori

2.2.1 Data Mining

Data Mining adalah bidang ilmu interdisipliner yang menggabungkan teknik-teknik pembelajaran mesin atau *Machine Learning*. Pengenalan pola (Pattern Recognition), Statistik, Database, dan visualisasi untuk mengekstrak informasi atau pengetahuan penting dari suatu dataset berukuran besar dengan teknik tertentu. Tujuan utamanya dari data mining adalah untuk menemukan pola-pola yang tersembunyi di dalam data dan kemudian menerapkan pengetahuan ini untuk tujuan yang bermanfaat. informasi yang dihasilkan dari proses data mining dapat digunakan untuk memprediksi hasil yang mungkin terjadi di masa depan atau membantu dalam pengambilan keputusan (Seo dkk, 2018). Proses data mining melibatkan beberapa tahapan, seperti pemilihan data yang relevan, preprocessing data untuk menghilangkan data yang tidak penting atau mengisi nilai yang hilang, Pemilihan algoritma yang tepat untuk menganalisis data, dan interpretasi hasil untuk mendapatkan pengetahuan yang berharga. Algoritma data mining yang umum digunakan termasuk klasifikasi, clustering, regresi asosiasi, dan analisis tren, Contoh penerapan data mining yang sering kita jumpai adalah ketika suatu perusahaan ingin meningkatkan penjualan produksinya. Dalam hal ini, data mining dapat digunakan untuk mengidentifikasi pola pembelian konsumen, menemukan asosiasi anata produk yang dibeli di masa depan. Dengan informasi ini, Perusahaan dapat mengembangkan strategi pemasaran yang lebih efektif untuk meningkatkan penjualan produknya.

2.2.1.1 Fungsi data mining

Data mining dapat membantu dalam pengambilan keputusan memproses data menganalisis dana besar yang kompleks dan heterogen beberapa teknik data mining yang umum digunakan diantaranya Klasifikasi, regresi, pengelompokan, dan asosiasi seperti pada gambar berikut.

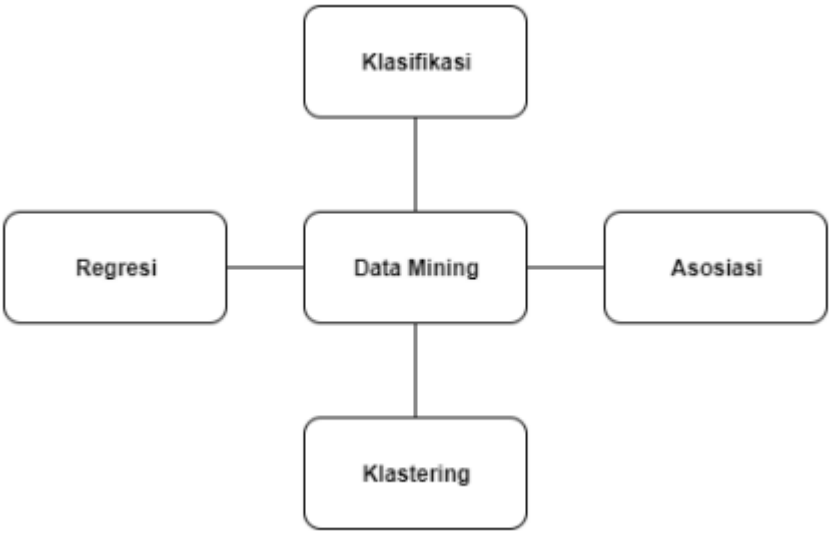

Gambar 2.3 Metode *Data Mining*

1) Klasifikasi

Metode Clustering memiliki fungsi untuk mengelompokan objek dalam beberapa kelompok berdasarkan kemiripan antara beberapa objek, dimana dalam masing-masing *Clustering* / Kelompok objek saling tidak mirip, karakteristik *Clustering* tidak memerlukan data pelatihan yang sudah diberi label.

2) Klasifikasi

Metode klasifikasi memiliki fungsi melakukan pengelompokan objek berdasarkan kelompok yang sudah ada, metode klasifikasi berbeda dengan *Clustering,* karakteristik metode klasifikasi membutuhkan data latih yang sudah diberi label atau kelas.

3) Regresi

Metode regresi memiliki fungsi hampir sama seperti metode Klasifikasi, yakni membutuhkan data latih yang lebih diberi label. Perbedaan antara

metode regresi dan klasifikasi berbeda pada *outputnya*, dimana *output* metode Klasifikasi adalah nilai diskrit, sedangkan metode regresi adalah nilai kontinyu.

4) Asosiasi

Metode asosiasi memiliki fungsi melakukan asosiasi objek dalam suatu *dataset* dengan menghitung beberapa kali pada data yang mengandung dua atom atau lebih yang saling berhubungan.

2.2.2 *Machine Learning*

Teknik Machine Learning memungkinkan sistem untuk belajar dari data menghasilkan hasil yang relevan daripada menggunakan pemrograman langsung. Pembelajaran mesin melibatkan pengguna berbagai algoritma untuk belajar dari data dengan cara mendeskripsikan data memprediksi hasil secara iteratif (Zhu dkk,2019). Namun hasil dari pembelajaran mesin dapat berubah tergantung pada kualitas data yang digunakan. Model *Machine Learning* diperoleh melalui latihan algoritma pembelajaran mesin menggunakan data. Setelah dilatih, model tersebut dapat menghasilkan output ketika diberi input. Contoh penggunaan *Machine Learning* adalah rekomendasi produk dalam e-commerce, di mana rekomendasi produk biasanya riwayat jelajah, riwayat pembelian, dan barang yang sebelumnya dilihat oleh pengguna.

2.2.3 Algoritma Klasifikasi

Metode pada analisis sentimen menggunakan algoritma klasifikasi. Pada penelitian ini algoritma yang digunakan untuk komparasi model adalah *Support Vector Machine* (SVM) dan *Random Forest* (RF). Penggunaan kedua metode ini dikarenakan pada penelitian-penelitian terdahulu algoritma ini lebih umum digunakan dalam analisis sentimen. Algoritma RF dipilih karena berdasarkan karakter *dataset* yang digunakan dalam penelitian ini berupa data yang rasio sentimennya tidak seimbang antara positif dan negatif (More et al., 2018). Algoritma RF dibandingkan dengan algoritma SVM dikarenakan karakteristik

algoritma ini yang terbaik bagus dalam klasifikasi dua kelas dan data imbalanced (Awad & Khanan, 2015; Brereton & Lloyd,2010;Khairunisa',2018). Untuk penjelasan masing-masing algoritma tersebut dijelaskan sebagai berikut.

2.2.4 *Random Forest*

Algoritma Random Forest (RF) adalah metode klasifikasi yang awalnya diperkenalkan oleh Leo Breiman pada 2004, berdasarkan sumber dari Biau (2012). Dimulai dengan pendekatan pohon keputusan pada tahun 2000, Breiman mengembangkannya menjadi analisis yang lebih rinci dalam bentuk algoritma RF. Mengadopsi ide dasar dari pohon keputusan, RF mempertahankan struktur pohon yang terdiri dari simpul-simpul dan jalur penghubung antara simpul. Ada tiga tipe simpul di dalam pohon keputusan: simpul akar, simpul terminal, dan simpul non-terminal. Simpul terminal tidak memiliki percabangan lebih lanjut, sedangkan simpul non-terminal memiliki cabang-cabang di bawahnya. Simpul akar adalah titik awal dari pohon. Beberapa terminologi utama dari pohon keputusan dijelaskan dalam Gambar 2.0.

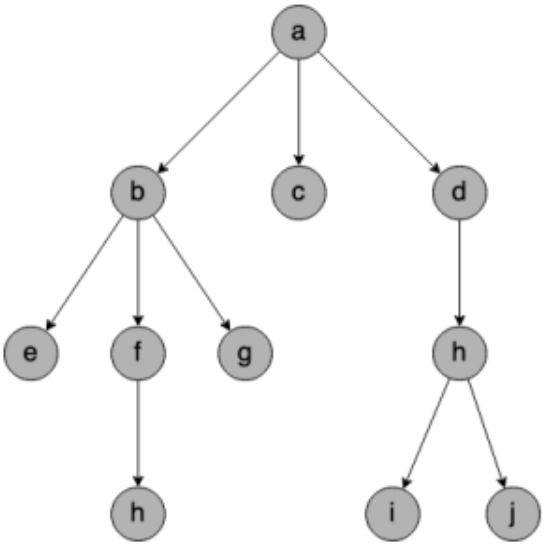

Gambar 2.4 Decision Tree

Sumber: (khairunnisa',2018);diolah kembali oleh penulis

1. Akar (*Root*)

   Akar merupakan suatu permulaan dari sebuah pohon keputusan. Oleh karena itu akar memiliki derajat yang bernilai 0. Dalam Gambar 2.3, titik a merupakan akar dari pohon.

2. Lintasan (*Path*)

   Garis penghubung antara simpul atau node disebut sebagai lintasan. Lintasan dapat menggambarkan posisi suatu simpul, sehingga simpul tersebut dapat disimpulkan sebagai orang tua (*parent*) atau anak (*child*)

3. Orang tua (*parent*) atau Anak (*child*)

   Dari Gambar 2.3, simpul b dan d memiliki cabang ke bawah. Dalam kata lain kedua simpul tersebut memiliki simpul-simpul di bawahnya. Sehingga simpul b dan d disebut sebagai orangtua dari beberapa simpul di bawanya.

4. Daun (*Leaf*)

   Daun merupakan simpul yang tidak memiliki anak. Karena merupakan simpul akhir dari percabangan, daun memiliki derajat keluar bernilai 0. Daun digambarkan oleh simpul c, e, h, i , dan j.

5. *Subtree*

   Subtree adalah pohon di dalam pohon yang lebih besar. Ilustrasi *subtree* terdapat pada Gambar 2.3. Apabila pohon dengan akan simpul a adalah pohon A, pohon dengan simpul d adalah pohon B, dan pohon dengan akar simpul h adalah pohon C, maka pohon H adalah *subtree* dari pohon B, dan pohon B adalah *subtree* dari pohon A.

6. Level atau Tingkat Pohon

Tingkat pohon diawali oleh akar yang memiliki nilai level 0. Apabila level akar dalah x, maka nilai tingkat berikutnya adalah (x+1).

7. Simpul Internal

   Simpul internal adalah simpul yang bukan merupakan akar dari pohon namun memiliki anak.

Random Forest (RF) adalah algoritma yang berasal dari metode Classification and Regression Tree (CART) menurut Dewi et al. (2011). Berlainan dengan algoritma pohon keputusan tradisional, RF menggunakan sejumlah besar pohon dalam proses pengambilan keputusannya. Kumpulan pohon-pohon ini membentuk apa yang disebut dengan "hutan" (Forest). Selain itu, RF adalah salah satu teknik machine learning yang mampu melakukan baik klasifikasi maupun regresi. Dalam prosesnya, RF memecah data ke dalam beberapa subset dan menciptakan pohon untuk tiap subset tersebut. Keputusan dari setiap pohon tersebut kemudian dikombinasikan untuk menghasilkan keputusan final.

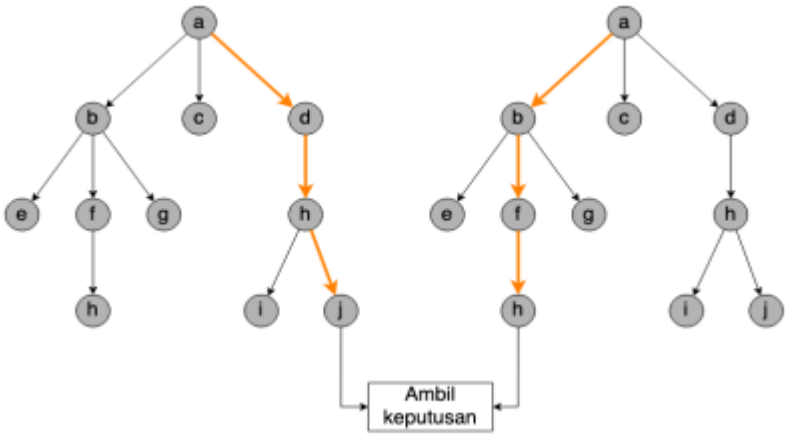

Gambar 2.5 Pengambilan keputusan RF

Sumber: (Khairunnisa',2018) diolah kembali oleh penulis

Algoritma RF tidak hanya berguna untuk klasifikasi tetapi juga untuk

regresi. Kelebihan RF termasuk kemampuannya dalam menangani dataset berukuran besar, menawarkan akurasi yang lebih tinggi dibandingkan dengan pohon keputusan, dan metodenya yang efektif dalam menghadapi kesalahan pada dataset yang fluktuatif. Beberapa faktor yang mempengaruhi akurasi RF antara lain jumlah pohon yang digunakan dalam pengambilan keputusan, kedalaman masing-masing pohon, dan fitur-fitur yang diintegrasikan. Dua komponen RF yang berkontribusi meningkatkan akurasi saat klasifikasi adalah banyaknya pohon dan seberapa dalam pohon tersebut. Dengan meningkatkan jumlah dan kedalaman pohon, akurasi cenderung membaik.

2.1.5 *Support Vector Machine*

Support Vector Machine (SVM) adalah teknik klasifikasi dan regresi yang dirancang oleh Bernhard, Vladimir Vapnik, dan Isabelle Guyon pada 1991. SVM, yang bisa bekerja pada data linier dan non-linier, sering diaplikasikan dalam analisis sentimen berbasis teks. Alasan utama SVM banyak dipilih dalam klasifikasi teks adalah karena kemampuannya mengelola overfitting pada data dengan banyak fitur dan mengecilkan fitur yang kurang berarti, sesuai dengan Awad & Khanna (2015).

Data dari berbagai kelompok biasanya tersebar dengan pola acak, memerlukan sebuah pembatas untuk mengkategorikan data ke dalam kelompok tertentu. Pembatas ini dikenal dengan istilah hyperplane. Dalam menetapkan hyperplane, penting untuk menentukan margin, yaitu jarak antara hyperplane dan data dari tiap kelompok. Jika hyperplane terlalu dekat atau terlalu jauh dari salah satu kelompok, bisa menghasilkan bias dalam klasifikasi. Hyperplane yang kurang tepat ini disebut garis diskriminasi, seperti yang diilustrasikan pada Gambar 2.5.

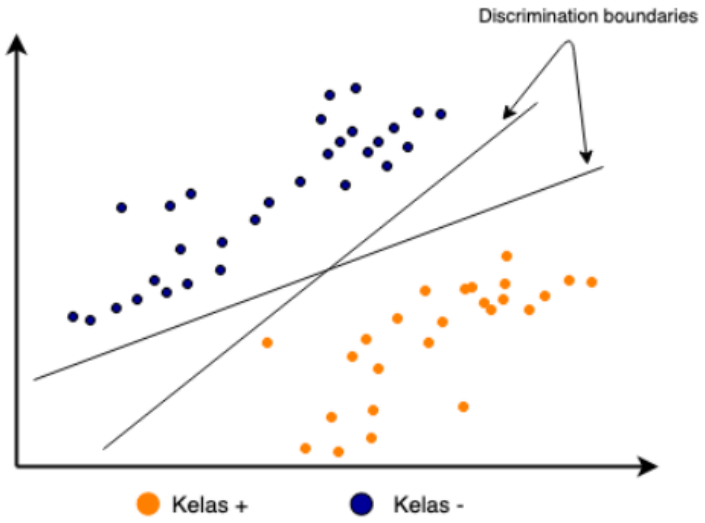

Gambar 2.6 Garis Diskriminasi

Sumber: (Khairunnisa',2018) diolah kembali oleh penulis

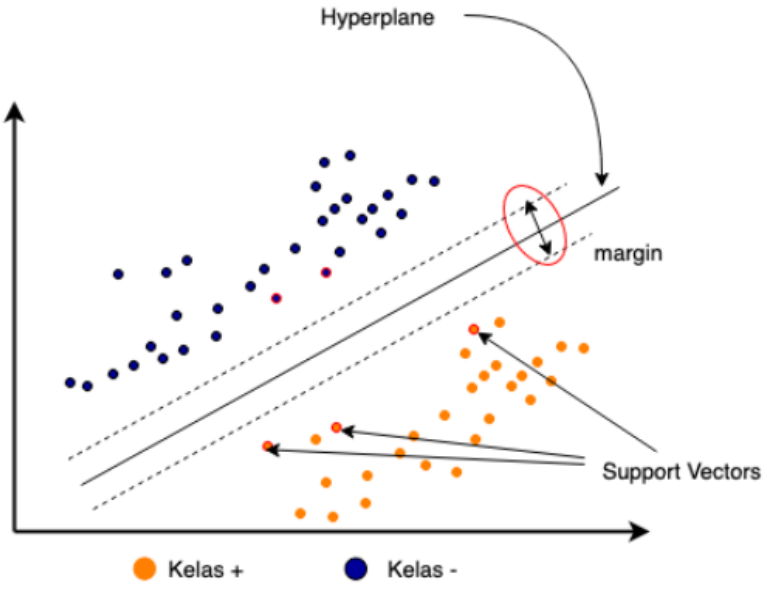

Gambar 2.7. *Hyperplane* SVM

Sumber: (Khairunnisa',2018) diolah kembali oleh penulis

Untuk mencegah keberadaan garis diskriminasi, hyperplane diposisikan sejauh mungkin dari setiap kelas. Dalam konteks ini, margin memegang peranan krusial dalam menetapkan posisi hyperplane. Dalam menentukan lokasi hyperplane yang ideal, SVM menggunakan titik-titik vektor yang berlokasi terdekat dengan margin, dikenal sebagai support vector atau vektor pendukung.

Pada Gambar 2.7, garis diagonal kontinu menandai hyperplane, sementara garis berbentuk putus-putus menunjukkan margin. Tanda panah dalam lingkaran berwarna merah menandakan bahwa margin tersebut adalah margin yang optimal. Titik berwarna kuning mewakili kelas negatif. Dalam gambar tersebut, terdapat titik-titik berwarna kuning dan biru dengan outline merah, menunjukkan bahwa mereka adalah vektor pendukung.

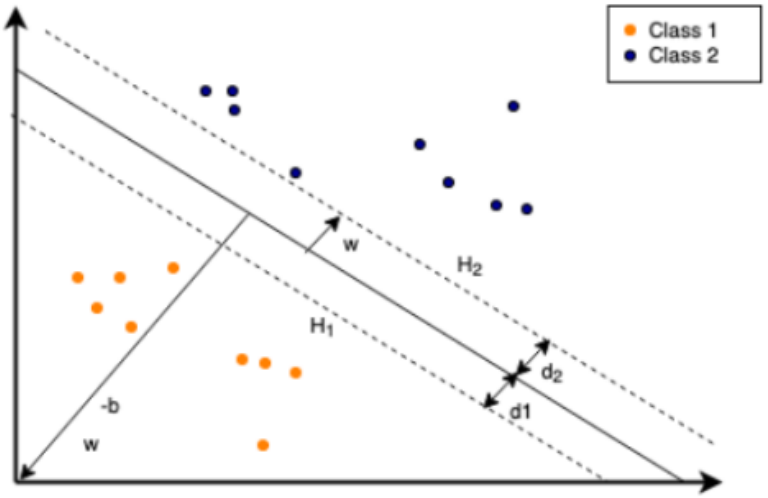

Gambar 2.8 *Hyperplane* dan *margin*

Sumber: (Khairunnisa',2018) diolah kembali oleh penulis

Margin yang dipilih untuk menentukan hyperplane adalah margin tertinggi. Pada Gambar 2.8, gabungan dari d1 dan d2 menghasilkan margin paling besar. Sementara itu, variabel w dan b diaplikasikan untuk mengkalkulasi *hyperplane*.

2.3 Hipotesis / Pertanyaan penelitian

Dalam melakukan teks, sentiment analysis berupa deteksi aduan kepada PT. Garuda Indonesia, Bagaimana perbandingan performa algoritma SVM dan Fandom Forest, kemudian topik keluhan apa saja yang diangkat dalam aduan kepada PT Garuda Indonesia di platform twitter, setelah dilakukan teks modeling.

BAB III
METODE PENELITIAN

3.1 Objek Penelitian

Objek penelitian ini adalah analisis tweet aduan yang ditujukan kepada PT Garuda Indonesia di platform Twitter menggunakan sentimen analisis. Penelitian ini bertujuan untuk menemukan metode deteksi tweet aduan dengan tingkat akurasi terbaik serta mengidentifikasi topik aduan yang paling umum ditujukan kepada PT Garuda Indonesia.

3.2 Alur Penelitian

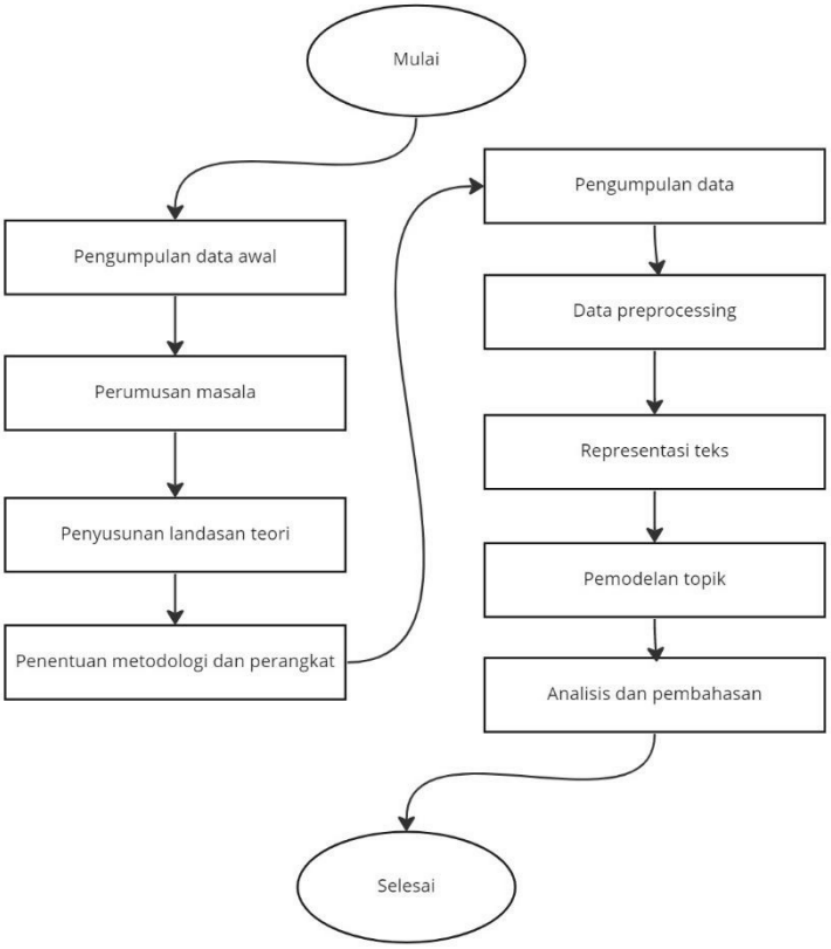

Gambar 3.1. Flowchart Alur kerja

1. Pengumpulan data awal

   Input pada tahap pengumpulan data awal berupa hasil *Scraping* dari tweet PT Garuda Indonesia yang dijadikan sebagai bahan identifikasi permasalahan. Selain itu penulis juga mengumpulkan data dari sumber *online* terkait dengan data aduan melalui internet.

2. Perumusan masalah

   Tahapan perumusan masalah dilakukan dengan studi literatur terhadap data *review* dan analisis data aduan. Pada tahap ini, masalah dirumuskan menggunakan analisis kesenjangan, merumuskan urgensi masalah dan dicari alternatif solusi yang telah didapatkan. Kemudian, disusunlah pertanyaan (*research question*) dan tujuan penelitian berdasarkan masalah dan solusi yang telah didapatkan tersebut.

3. Penyusunan landasan teori

   Berdasarkan *research question* yang telah disusun sebelumnya, dalam tahap ini dilakukan penyusunan landasan teori terkait analisis sentiment dan pemodelan topik. Juga dilakukan pengkajian terhadap penelitian-penelitian terdahulu yang terkait identifikasi dan eksplorasi data aduan pada media sosial dan metode serupa yang digunakan. Selanjutnya dilakukan analisis 3C+2S untuk menghasilkan analisis perbandingan dan disusun dalam kerangka teoritis yang menjadi masukan dalam tahap selanjutnya.

4. Penentuan metode dan perangkat

   Kerangka teoritis dan penelitian-penelitian terkait yang sudah disusun dijadikan dasar untuk studi literatur lebih lanjut guna mendapatkan data hasil sintesis dan ragam metode serta perangkat yang digunakan dalam pengumpulan data, pengolahan data dan juga analisis. Metodologi yang digunakan adalah kerangka kerja *Natural Language processing* dan *topik modelling* untuk mendapatkan hasil penelitian sesuai tujuan yang telah dirumuskan.

5. Pengumpulan data

   Berdasarkan tahap proses *text mining*, tahap pengumpulan data dilakukan sebagai upaya untuk membuat korpus data. Dalam penelitian ini, penulis mengumpulkan dan menggunakan data dari Twitter. Data yang diambil adalah data dengan *Keyword* tertentu yang berhubungan dengan data

aduan sesuai studi kasus penelitian dan dalam kurun waktu yang telah ditentukan.

6. *Data preprocessing*

Tahap preprocessing merupakan tahap dimana dataset mentah yang telah dilabeli selanjutnya dibersihkan untuk kemudian siap menjadi data label yang dapat diolah

7. Representasi teks

Dataset yang sudah dibersihkan tidak dapat langsung diolah dengan metode pengolahan teks, oleh karena itu dalam tahap ini dilakukan proses representasi dengan menggunakan TF-IDF. Dari tahap ini dihasilkan data fitur-fitur teks yang selanjutnya diproses baik itu untuk clustering maupun untuk pemodelan topik.

8. Pemodelan topik

Tahap pemodelan topik dilakukan pada data-data yang bersifat negatif atau bisa disebut sebagai aduan. Data ini dimodelkan dengan menggunakan metode pemodelan topik Latent Dirichlet Allocation (LDA). Tahap ini akan menghasilkan beberapa Cluster atau topik yang akan dianalisis pada tahap selanjutnya.

9. Analisis dan pembahasan

Tahap analisis dan pembahasan adalah tahapan dimana akan dilakukan analisis terhadap hasil Clustering dan hasil pemodelan topik. Analisis dilakukan secara deskriptif dengan pembahasan yang detail terkait hasil penelitian yang telah dilakukan.

3.3 Alat dan Bahan

3.2.1 Alat

A. Perangkat keras

Perangkat keras yang digunakan dalam penelitian ini adalah laptop dengan spesifikasi prosesor AMD Ryzen 3 4000U, CPU @ 2.70Ghz, RAM 8GB, dan SSD 512GB laptop digunakan untuk pemrosesan seluruh tahapan pengujian.

B. Perangkat Lunak

1. Google chrome atau browser web lainnya akan digunakan untuk mengakses platform Google Collab dan mengoperasikannya.
2. *Google colab*, Yaitu aplikasi yang digunakan untuk menjalankan dengan bahasa pemrograman *python* melalui *web browser*.
3. Bahasa pemrograman *python.*

3.3.2 Bahan

Bahan atau data yang digunakan dalam penelitian ini adalah data tweet yang ditujukan kepada PT Garuda Indonesia di platform Twitter. Data tweet ini akan diakses melalui API Twitter dengan menggunakan kata kunci yang relevan terkait perusahaan. Pengumpulan data akan berfokus pada periode waktu tertentu untuk memastikan data yang relevan dan terbaru digunakan dalam analisis

REFERENSI

Kemp, S. (2020*). Digital 2020: October Global Statshot*. Datareportal : https://datareportal.com/reports/digital-2020-october-global-statshot.

Asosiasi Penyelenggaraan Jasa Internet Indonesia (2020). Laporan Survei Internet APJII 2019 – 2020 (Q2) Jakarta : APJII. https://link.springer.com/chapter/10.1007/978-1-4302-5990-9_3.

Alves, H., Fernandes, C., & Raposo, M. (2016). Social Media Marketing: A Literature Review and Implications. Psychology & Marketing, 33(12), 1029–1038.

Marshall, G. W., Moncrief, W. C., Rudd, J. M., & Lee, N. (2012). Revolution in sales: The impact of social media and related technology on the selling environment. Journal of Personal Selling & Sales Management, 32(3), 349-363.

Punel, A., & Ermagun, A. (2018). Using Twitter network to detect market segments in the airline industry. Journal of Air Transport Management, 73(May), 67–76.https://doi.org/10.1016/j.jairtraman.2018.08.004. Jakarta: Universitas Indonesia.

Peralta, R. L. (2019). How vlogging promotes a destination image: A narrative analysis of popular travel vlogs about the Philippines. Place Branding and Public Diplomacy, 15(4), 244-256.

Hailong, Z., Wenyan, G., & Bo, J. (2014). Machine learning and lexicon based methods for sentiment classification: A survey. In 2014 11th Web Information System and Application Conference (pp. 262-265). IEEE. https://doi.org/10.1109/WISA.2014.55.

Hernandez-Suarez, A., Sanchez-Perez, G., Martinez-Hernandez, V., Perez-Meana, H., Toscano-Medina, K., Nakano, M., & Sanchez, V. (2017). Predicting political mood tendencies based on Twitter data. In 2017 5th International Workshop on Biometrics and Forensics (IWBF) (pp. 1-6). IEEE.

Rahayuningtyas, N. D. (2020). *Analisis Teks pada Tweet berbahasa indonesia Untuk Mendeteksi pro kontra Vaksinasi Menggunakan Pendekatan Stance Detection Dan Topic Modeling*. Jakarta : Universitas Indonesia.

Damayanti, N. R. (2017). Perbandingan Metode Pembobotan Fitur terhadap Performa algoritme Support Vector Machine pada Analisis Sentimen Operator Telekomunikasi di Indonesia. Yogyakarta: Universitas Gadjah Mada.

Budiharto, W., & Meiliana, M. (2018) Prediction and analysis of Indonesia Presidential election from Twitter using sentiment analysis. Journal of Big Data, 5(1), 1-10 : https://journalofbigdata.springeropen.com/articles/10.1186/s40537-018-0164-1.

Pill, S., Harvey, S., & Hyndman, B. (2017). *Novel research approaches to gauge global teacher familiarity with game-based teaching in physical education: An exploratory #Twitter analysis*. Asia-Pacific Journal of Health, Sport and Physical Education, 8(2), 161-178.

Soleymani, M., Garcia, D., Jou, B., Schuller, B., Chang, S. F., & Pantic, M.(2017). *A survey of multimodal sentiment analisis.* Image and Vision Computing,65, 3-14.

Pranckevičius, T., & Marcinkevičius, V. (2017). *Comparison of naive bayes, random forest, decision tree, support vector machines, and logistic regression classifiers for text reviews classification*. Baltic Journal of Modern Computing, 5(2), 221.

Curiskis, S. A., Drake, B., Osborn, T. R., & Kennedy, P. J. (2020). *An evaluation of document clustering and topic modelling in two online social networks: Twitter and Reddit*. Information Processing & Management, 57(2), 102034.

Llewellyn, C., Cram, L., Favero, A., & Hill, R. L. (2018). Russian troll hunting in a Brexit Twitter archive. In Proceedings of the 18th ACM/IEEE on Joint Conference on Digital Libraries (pp. 361-362).

Prabhakar Kaila, D.., & Prasad, D. A. (2020). *Information flow on Twitter-Corona virus outbreak-topic modelling approach*. International Journal of Advanced Research in Engineering and Technology (IJARET), 11(3).

McCay-Peet, L., & Quan-Haase, A. (2017). *What is social media and what questions can social media research help us answer*. In The SAGE handbook of social media research methods (pp. 13–26). California: SAGE Publications.

Ellison, N. B., & Body, D. M. (2013). *Sociality Through Social Network Sites*. In The Oxford Handbook of Internet Studies. Oxford Handboos:https://academic.oup.com/edited-volume/34364/chapter-abstract/328422615?redirectedFrom=fulltext.

Allahyari, M., Pouriyeh, S., Assefi, M., Safaei, S., Trippe, E. D., Gutierrez, J. B., & Kochut, K. (2017). A brief survey of text mining: Classification, clustering and extraction techniques. arXiv preprint. arXiv:1707.02919.

García, S., Luengo, J., & Herrera, F. (2015). Data preprocessing in data mining (Vol. 72). Switzerland: Springer International Publishing.

Salsabila N. A., Winatmoko, Y. A., Septiandri, A. A., Jamal, A. (2018). *Colloquial Indonesian Lexicon*. 2018 International Conference on Asian Language Processing(IALP). doi:10.1109/ialp.2018.8629151.

Aprianto, A. (2016). *Analisis Sentimen dan Peringkasan Opini pada Ulasan Produk menggunakan Algoritma Random Forest*. Bandung: Telkom University.

Hegde, Y.., & Padma, S. K. (2017). *Sentiment Analisis Using Random Forest Ensemble for Mobile Product Reviews in Kannada*. 2017 IEEE 7th International Advance Computing Conference (IACC), 777-782. https://doi.org/10.1109/IACC.2017.0160.

Khairunnisa, S. N. (2018). *Perbandingan Kinerja Algoritme Klasifikasi Support Vector Machine dan Random Forest Terhadap Domain Silang Pada Analisis Sentimen Berbasis Teks Berbahasa Indonesia.* Yogyakarta : Universitas Gadjah Mada